BÁO CÁO PHÂN TÍCH VÀ ĐÁNH GIÁ TẬP DỮ LIỆU (DATASET ANALYSIS)

ĐỀ TÀI: DỰ ĐOÁN GIÁ BẤT ĐỘNG SẢN (HOUSE PRICE PREDICTION)

MÔN HỌC: HỌC MÁY (MACHINE LEARNING) - PTIT

---

1. TỔNG QUAN TỪNG DATASET (DATASET OVERVIEW)

1.1. Bảng tóm tắt tổng quan 2 Dataset

Dataset	Samples	Features	Target	Ý nghĩa	Nguồn
Dataset 1: King County House Sales	21,613 21,613 dòng	21 21 cột	price (Đô la Mỹ - USD)	Dự đoán giá bán nhà ở riêng lẻ tại quận King County (bao gồm thành phố Seattle), bang Washington, Hoa Kỳ (dữ liệu giao dịch 2014–2015).	https://www.kaggle.com/datasets/harlfoxem/housesalesprediction
Dataset 2: Indian Urban Housing	80,000 80,000 dòng (Train) 20,000 20,000 dòng (Test)	18 18 cột	Price_INR_Lakhs (Lakhs - Rúp Ấn Độ)	Dự đoán giá bán căn hộ, biệt thự và nhà phố tại 10 10 đại đô thị lớn của Ấn Độ (Mumbai, Delhi, Bangalore, Hyderabad, Pune, Kolkata...).	https://www.kaggle.com/competitions/indian-urban-house-price-prediction/data

---

1.2. Chi tiết từng bộ dữ liệu

A. Dataset 1: King County House Sales (kc_house_data.csv)

- Nguồn dữ liệu: Kaggle / King County Department of Assessments (Cơ quan Thẩm định và Thuế Bất động sản Quận King, Washington, Mỹ).
- Quy mô: 21,613 quan sát, 21 cột thuộc tính.
- Target Variable : price (Giá bán nhà thực tế, tính bằng USD).
- Các đặc trưng quan trọng nhất tác động đến giá:
    1. sqft_living (Diện tích không gian sinh hoạt trong nhà): Tương quan tuyến tính mạnh nhất với giá (r=0.702).
    2. grade (Điểm chất lượng thiết kế và thi công do chính quyền cấp 1–13): Tương quan rất cao (r=0.667).
    3. lat, long (Toạ độ địa lý GPS) & zipcode (Mã bưu chính): Phản ánh vị trí trung tâm Seattle gần hồ Washington đắt giá.
    4. sqft_living15 (Diện tích sinh hoạt trung bình của 15 căn nhà lân cận): Phản ánh đẳng cấp kinh tế của khu dân cư (r=0.585).

B. Dataset 2: Indian Urban House Price Prediction (train.csv & test.csv)

- Nguồn dữ liệu: Thử thách Khoa học Dữ liệu (Data Science Challenge / Kaggle) về thị trường bất động sản đô thị Ấn Độ.
- Quy mô: 80,000 dòng huấn luyện (Train), 20,000 dòng kiểm thử (Test), 18 cột thuộc tính.
- Target Variable: Price_INR_Lakhs (Giá bán theo đơn vị Lakhs;
- 1 Lakh=100,000 INR≈30 triệu VNĐ
- Các đặc trưng quan trọng nhất tác động đến giá:
    1. Super_Area_SqFt & Carpet_Area_SqFt (Tổng diện tích xây dựng và diện tích sử dụng lọt lòng): Tương quan cao nhất (r≈0.635).
    2. City (Thành phố): Giá nhà tại các trung tâm tài chính lớn như Mumbai (308.9 Lakhs) và Delhi (227.0 Lakhs) cao gấp 3−5 lần các thành phố vệ tinh.
    3. Locality_Type (Phân khúc khu vực): Khu vực Cao cấp (Premium) có giá đắt gấp 5 lần khu vực Bình dân (Affordable).
    4. Distance_to_City_Center_km & Distance_to_Metro_km: Khoảng cách đến trung tâm và ga tàu điện ngầm tỷ lệ nghịch với giá bán.

---

2. PHÂN TÍCH CẤU TRÚC DỮ LIỆU (DATA STRUCTURE ANALYSIS)

2.1. Cấu trúc Dataset 1: King County House Sales (kc_house_data.csv)

Tên cột (Feature)	Kiểu dữ liệu (Data Type)	Phân loại trong ML	Ý nghĩa thực tế

id	Chuỗi / Số	Identifier	Mã định danh riêng của từng căn nhà (loại bỏ khi huấn luyện mô hình).
date	Chuỗi (object)	Datetime	Ngày thực hiện giao dịch mua bán nhà (Ví dụ: 20141013T000000).
price	Số thực (float64)	Target Variable	Giá bán của căn nhà (tính theo USD) - Biến mục tiêu cần dự đoán.
bedrooms	Số nguyên (int64)	Numeric (Discrete)	Số lượng phòng ngủ của ngôi nhà.
bathrooms	Số thực (float64)	Numeric (Continuous)	Số lượng phòng tắm (0.75 = phòng có bồn rửa, toilet, vòi sen; 1.0 = đầy đủ bồn tắm).
sqft_living	Số nguyên (int64)	Numeric (Continuous)	Diện tích không gian sinh hoạt bên trong nhà (tính bằng bộ vuông - sqft).
sqft_lot	Số nguyên (int64)	Numeric (Continuous)	Tổng diện tích khuôn viên mảnh đất (sqft).
floors	Số thực (float64)	Numeric	Số tầng của ngôi nhà (1,1.5,2,2.5,3,3.5).
waterfront	Số nguyên (int64)	Binary / Boolean	Nhà có view nhìn thẳng ra bờ hồ/biển hay không (0 = Không, 1 = Có).
view	Số nguyên (int64)	Categorical (Ordinal)	Điểm đánh giá tầm nhìn/cảnh quan đẹp của ngôi nhà (thang điểm 0 đến 4).
condition	Số nguyên (int64)	Categorical (Ordinal)	Tình trạng bảo trì, độ mới của căn nhà (thang điểm 1 đến 5).
grade	Số nguyên (int64)	Categorical (Ordinal)	Điểm chất lượng thiết kế & vật liệu xây dựng theo chuẩn quận King (thang điểm 1 đến 13).
sqft_above	Số nguyên (int64)	Numeric (Continuous)	Diện tích phần nhà trên mặt đất (không tính tầng hầm).
sqft_basement	Số nguyên (int64)	Numeric (Continuous)	Diện tích tầng hầm (nếu =0 là nhà không có tầng hầm).
yr_built	Số nguyên (int64)	Numeric	Năm xây dựng ngôi nhà (từ năm 1900 đến 2015).
yr_renovated	Số nguyên (int64)	Numeric	Năm cải tạo, sửa chữa nhà (nếu =0 là chưa từng cải tạo).

zipcode	Số nguyên (int64)	Categorical (Nominal)	Mã bưu chính khu vực (đại diện cho vị trí phân vùng tại Mỹ).
lat	Số thực (float64)	Numeric (Geographic)	Vĩ độ địa lý (Toạ độ GPS).
long	Số thực (float64)	Numeric (Geographic)	Kinh độ địa lý (Toạ độ GPS).
sqft_living15	Số nguyên (int64)	Numeric (Continuous)	Diện tích sinh hoạt trung bình của 15 căn nhà hàng xóm lân cận nhất.
sqft_lot15	Số nguyên (int64)	Numeric (Continuous)	Diện tích khuôn viên đất trung bình của 15 căn nhà hàng xóm lân cận nhất.

2.2. Cấu trúc Dataset 2: Indian Urban Housing (train.csv)

Tên cột (Feature)	Kiểu dữ liệu (Data Type)	Phân loại trong ML	Ý nghĩa thực tế
Property_ID	Chuỗi (object)	Identifier	Mã định danh bất động sản (Ví dụ: PROP-041055) → Loại bỏ khi train.
City	Chuỗi (object)	Categorical (Nominal)	Tên thành phố (10 đô thị: Mumbai, Delhi, Bangalore, Pune, Kolkata, Hyderabad, Chennai, Chandigarh, Ahmedabad, Jaipur).
Locality_Type	Chuỗi (object)	Categorical (Ordinal)	Phân khúc khu vực dân cư (Affordable - Bình dân, Mid-Range - Trung cấp, Premium - Cao cấp).
Property_Type	Chuỗi (object)	Categorical (Nominal)	Loại hình nhà ở (Apartment - Căn hộ chung cư, Villa - Biệt thự, Builder Floor, Independent House).

BHK	Số nguyên (int64)	Numeric (Discrete)	Số phòng ngủ (Bedroom, Hall, Kitchen - từ 1 đến 6 phòng).
Bathrooms	Số nguyên (int64)	Numeric (Discrete)	Số lượng phòng vệ sinh/phòng tắm (từ 1 đến 6 phòng).
Super_Area_SqFt	Số thực (float64)	Numeric (Continuous)	Tổng diện tích xây dựng tính cả tường bao và hành lang chung (sqft).
Carpet_Area_SqFt	Số thực (float64)	Numeric (Continuous)	Diện tích sử dụng thực tế lọt lòng bên trong căn hộ (sqft).
Floor_Number	Số nguyên (int64)	Numeric (Discrete)	Vị trí tầng của căn hộ (Tầng 0 là tầng trệt, tối đa tầng 43).
Total_Floors	Số nguyên (int64)	Numeric (Discrete)	Tổng số tầng của toà nhà chung cư.
Age_of_Property	Số nguyên (int64)	Numeric (Discrete)	Tuổi thọ của căn nhà (tính theo số năm, từ 0 đến 39 năm).
Furnishing_Status	Chuỗi (object)	Categorical (Ordinal)	Mức độ trang bị nội thất (Furnished - Đầy đủ, Semi-Furnished - Cơ bản, Unfurnished - Nhà thô).
Parking	Số nguyên (int64)	Binary / Boolean	Có chỗ đỗ xe ô tô hay không (0 = Không, 1 = Có).
Lift_Available	Số nguyên (int64)	Binary / Boolean	Toà nhà có thang máy hay không (0 = Không, 1 = Có).
Gated_Community	Số nguyên (int64)	Binary / Boolean	Nằm trong khu đô thị khép kín có bảo vệ 24/7 hay không (0 = Không, 1 = Có).
Distance_to_Metro_km	Số thực (float64)	Numeric (Continuous)	Khoảng cách từ nhà đến ga tàu điện ngầm gần nhất (tính bằng km).

Distance_to_City_Center_km	Số thực (float64)	Numeric (Continuous)	Khoảng cách từ nhà đến trung tâm thành phố (tính bằng km km).
Price_INR_Lakhs	Số thực (float64)	Target Variable	Giá bán của căn nhà (tính theo Lakhs) - Biến mục tiêu cần dự đoán.

---

3. KIỂM TRA CHẤT LƯỢNG DỮ LIỆU (DATA QUALITY ANALYSIS)

3.1. Missing values (Giá trị bị thiếu / Rỗng)

- Dataset 1 (King County): 0 giá trị thiếu (0.00%) trên toàn bộ 21,613 dòng và 21 cột.
- Dataset 2 (Indian Urban): 0 giá trị thiếu (0.00%) trên cả tập Train (80,000 dòng) và tập Test (20,000 dòng).
- Kết luận & Xử lý: Cả hai bộ dữ liệu đều đạt chuẩn toàn vẹn cấu trúc lý tưởng (100% sạch). Nhóm không cần phải áp dụng các thuật toán gán dữ liệu khuyết thiếu phức tạp (Imputation), triệt tiêu hoàn toàn nguy cơ rò rỉ dữ liệu (Data Leakage).

3.2. Duplicate data (Dữ liệu trùng lặp)

- Dataset 1 (King County): 0 bản ghi trùng lặp (0.00%). Toàn bộ id đại diện cho các giao dịch độc lập.
- Dataset 2 (Indian Urban): 0 bản ghi trùng lặp (0.00%). Toàn bộ Property_ID là duy nhất.
- Kết luận: Không cần xóa dòng trùng, dữ liệu sẵn sàng cho các bước xử lý số học.

3.3. Outliers (Dữ liệu ngoại lai) và Cách xử lý

Loại ngoại lai	Phát hiện trên Dataset 1 (King County)	Phát hiện trên Dataset 2 (Indian Urban)	Quyết định xử lý & Giải thích lý do
Bất thường về số phòng	Có 1 bản ghi (id = 15870) có 33 33 phòng ngủ nhưng diện tích sinh hoạt chỉ 1,620 sqft	Không có bất thường (BHK từ 1 đến 6 phòng rất hợp lý).	👉 Loại bỏ hoặc sửa về 3 phòng ngủ: Đây là lỗi gõ phím (typo) rõ ràng trong quá trình nhập liệu, nếu giữ lại sẽ làm sai lệch mô hình hồi quy.

	1,620 sqft.		
Bất thường về diện tích	Không có nhà diện tích =0. Diện tích nhỏ nhất là 290 sqft (≈27 m2).	Có 33 căn hộ có diện tích cực nhỏ Super_Area_SqFt < 100 (nhỏ nhất là 16 sqft).	👉 Lọc bỏ 33 dòng này: Căn hộ <100 sqft (≈9 m2) là lỗi nhập liệu hoặc ki-ốt bán hàng, không đúng bản chất nhà ở đô thị.
Giá nhà quá cao (Biệt thự sang trọng)	1,146 mẫu (5.3%) có giá >$1.1M USD (cao nhất $7.7M).	Một số biệt thự tại Mumbai có giá >1,000 Lakhs (cao nhất 3,334 Lakhs).	👉 GIỮ LẠI và áp dụng log(1+y): Đây là các bất động sản phân khúc hạng sang thực tế, không phải nhiễu. Dùng hàm logarit tự nhiên sẽ nén các giá trị lớn lại, giúp phân bố chuyển về dạng hình chuông (chuẩn hóa).

---

4. SO SÁNH 2 DATASET (DATASET COMPARISON)

Tiêu chí so sánh	Dataset 1: King County (kc_house_data)	Dataset 2: Indian Urban Housing
Số lượng mẫu (Samples)	21,613 dòng	80,000 dòng Train (20,000 Test)
Số lượng feature	21 cột (18 cột dự đoán)	18 cột (16 cột dự đoán)
Biến mục tiêu (Target)	price (Đô la Mỹ - USD)	Price_INR_Lakhs (Lakhs - Đồng Rúp Ấn Độ)
Missing values	0 giá trị rỗng (0%)	0 giá trị rỗng (0%)
Categorical features	Ít (1 cột date, 1 cột zipcode)	Vừa phải (4 cột: City, Locality, Type, Furnishing)
Độ khó Preprocessing	Rất thấp (Dễ): Log-transform, Scale, tách Date	Rất thấp (Dễ): One-Hot Encoding, Scale, Log-transform

Mức độ thực tế & Chiều sâu	Thể hiện mạnh về toạ độ không gian GPS (lat, long) và điểm thẩm định chất lượng (grade).	Thể hiện mạnh về kinh tế đô thị (phân khúc, khoảng cách đến ga tàu Metro, trung tâm).

---

5. ĐÁNH GIÁ KHẢ NĂNG SỬ DỤNG CHO MACHINE LEARNING

Cả hai bộ dữ liệu đều cực kỳ phù hợp
100%
100% cho bài toán Hồi quy (Regression):

1. Dung lượng lý tưởng: Kích thước đều >20,000 mẫu, đủ lớn để chia Train / Validation / Test mà không lo bị học vẹt (Overfitting).
2. Đặc trưng có ý nghĩa kinh tế rõ ràng: Diện tích, số phòng, vị trí địa lý đều có mối tương quan mạnh mẽ với giá bán.

Đánh giá chi tiết trên 5 Thuật toán Học máy:

1. Linear Regression / Ridge / Lasso (Hồi quy tuyến tính):
    - Đánh giá: Phù hợp làm mô hình chuẩn (Baseline).
    - Giải thích: Sau khi áp dụng biến đổi logarit ln(1+y) cho biến mục tiêu và chuẩn hóa các biến diện tích, mô hình tuyến tính giải thích được khoảng ≈70%−72% sự biến thiên của giá nhà.
2. Decision Tree (Cây quyết định):
    - Đánh giá: Tốt.
    - Giải thích: Tự động phân chia các ngưỡng giá theo từng khu vực (zipcode hoặc City) và từng khoảng diện tích mà không yêu cầu chuẩn hóa dữ liệu ($R2 \approx 0.77-0.79$)

3. Random Forest (Rừng ngẫu nhiên):
    - Đánh giá: Rất xuất sắc.
    - Giải thích: Cơ chế Ensemble (kết hợp 100 cây quyết định) giúp triệt tiêu hiện tượng Overfitting của một cây đơn lẻ, nắm bắt trọn vẹn các mối quan hệ phi tuyến phức tạp giữa tiện ích và giá ($R2 \approx 0.87-0.88$).
4. XGBoost / LightGBM (Extreme Gradient Boosting):
    - Đánh giá: MÔ HÌNH TỐI ƯU NHẤT (Best Model).
    - Giải thích: Thuật toán tăng cường độ dốc (Boosting) học tuần tự từ các sai số của cây trước đó, tối ưu hóa hàm mất mát cực tốt trên dữ liệu bảng, cho kết quả R2 cao nhất (0.89−0.90) và tốc độ chạy chỉ mất 1−2 giây.
5. Neural Network - MLPRegressor (Mạng nơ-ron truyền thẳng đa tầng):
    - Đánh giá: Rất phù hợp.
    - Giải thích: Nhờ kích thước dữ liệu lớn (>20,000 mẫu), mạng nơ-ron có đủ dữ liệu để học các trọng số phức tạp mà không bị thiếu hụt dữ liệu như ở các dataset nhỏ ($R2 \approx 0.85-0.86$).

6. ĐỀ XUẤT QUY TRÌNH TIỀN XỬ LÝ DỮ LIỆU (PREPROCESSING PIPELINE)

Sơ đồ luồng tiền xử lý (Pipeline Flowchart):

Raw Dataset (Dữ liệu ban đầu)
↓
Data Cleaning (Làm sạch: Bỏ cột ID, xử lý ngoại lai 33 phòng/diện tích <100)
↓
Missing Value Handling (Xác nhận 0% missing, không cần gán rỗng)
↓
Feature Selection & Encoding (One-Hot Encoding cho City, Type, Locality...)
↓
Feature Engineering (Trích xuất Year/Month, tuổi nhà, Log-transform Target)
↓
Train/Test Split (Chia 80% Train - 20% Test, random_state=42)
↓
Feature Scaling (StandardScaler trên X_train, fit sang X_test)
↓
Model Training (Huấn luyện 5 thuật toán ML & Đánh giá)

Chi tiết từng bước thực hiện:

- Bước 1 - Data Cleaning (Làm sạch):
  - King County: Bỏ cột id; xóa dòng ngoại lai 33 phòng ngủ.
  - Indian Urban: Bỏ cột Property_ID; xóa 33 dòng có Super_Area_SqFt < 100.
- Bước 2 - Missing Value Handling (Xử lý thiếu):
  - Cả 2 bộ đều 0% rỗng nên chỉ cần kiểm tra lại bằng assert df.isnull().sum().sum() == 0.
- Bước 3 - Feature Encoding (Mã hóa đặc trưng danh mục):
  - Sử dụng One-Hot Encoding (pd.get_dummies với drop_first=True) cho các cột chữ: City, Locality_Type, Property_Type, Furnishing_Status.
- Bước 4 - Feature Engineering (Tạo đặc trưng mới):
  - King County: Tách date thành sale_year, sale_month; tính house_age = sale_year - yr_built.
  - Cả 2 bộ: Biến đổi logarit cho biến mục tiêu: y=ln(1+Price)

- Bước 5 - Train/Test Split (Chia tập dữ liệu):
  - Chia dữ liệu theo tỷ lệ 80% tập huấn luyện (Train) và 20% tập kiểm thử (Test) bằng train_test_split(..., test_size=0.2, random_state=42).
- Bước 6 - Feature Scaling (Chuẩn hóa thang đo):
  - Áp dụng StandardScaler() hoặc MinMaxScaler() cho các biến số (Area, Distance...) để phục vụ các mô hình Linear Regression và Neural Network.

- Bước 7 - Model Training (Huấn luyện):
    - Đưa dữ liệu đã chuẩn hóa vào huấn luyện đồng thời 5 thuật toán và tính các độ đo R2, MAE, RMSE, MAPE.

---

7. ĐỀ XUẤT CÁCH CHIA CÔNG VIỆC NHÓM (4 THÀNH VIÊN)

Thành viên	Nhiệm vụ chính	Chi tiết công việc cụ thể cần nộp
Thành viên 1 (Data Analyst & Preprocessing)	Khám phá & Làm sạch dữ liệu (EDA & Cleaning)	• Thống kê mô tả (Mean, Median, Min, Max, Skewness). • Vẽ biểu đồ phân bố giá, biểu đồ nhiệt ma trận tương quan (Heatmap). • Viết code làm sạch ngoại lai và mã hóa One-Hot.
Thành viên 2 (Feature Engineer)	Kỹ thuật đặc trưng & Chuẩn hóa (Feature Engineering & Scaling)	• Trích xuất đặc trưng thời gian (SaleYear, SaleMonth, HouseAge). • Thực hiện biến đổi logarit ln(1+y) cho Target. • Phân chia Train/Test Split và chuẩn hóa bằng StandardScaler.
Thành viên 3 (Machine Learning Engineer)	Huấn luyện mô hình (Model Training & Tuning)	• Cài đặt mã nguồn huấn luyện 5 mô hình (Linear Regression, Decision Tree, Random Forest, XGBoost, Neural Network MLP). • Tinh chỉnh siêu tham số (Hyperparameter Tuning bằng GridSearchCV hoặc RandomizedSearchCV).
Thành viên 4 (Evaluator & Report Lead)	Đánh giá, So sánh & Viết Báo cáo (Evaluation & Documentation)	• Tính toán bảng so sánh các chỉ số (R2, MAE, RMSE, MAPE) giữa 2 dataset. • Vẽ biểu đồ trực quan hóa (Predicted vs Actual, Feature Importance, Residual Plot). • Tổng hợp Word/LaTeX làm Báo cáo chính thức và làm Slide thuyết trình.

---

8. KẾT LUẬN CUỐI CÙNG (FINAL RECOMMENDATION)

8.1. Đánh giá so sánh lựa chọn:

- Dataset dễ triển khai nhất: Cả hai đều rất dễ triển khai do 0% giá trị thiếu. Tuy nhiên, kc_house_data.csv gọn gàng hơn vì hầu hết các cột đã ở dạng số sẵn.
- Dataset giúp bài báo cáo có chiều sâu thực tế nhất: Dataset 2 (Indian Urban Housing) vì có đầy đủ các yếu tố của quy hoạch đô thị hiện đại (khoảng cách ga tàu

điện ngầm, khoảng cách trung tâm, phân khúc cao cấp/bình dân, thang máy, an ninh khu đô thị).

8.2. Đề xuất chiến lược: CÓ NÊN DÙNG CẢ 2 DATASET KHÔNG?

👉 RẤT NÊN SỬ DỤNG CẢ 2 DATASET TRONG CÙNG 1 BÀI BÁO CÁO!

5 Lý do thuyết phục để đưa cả 2 bộ vào bài tập lớn:

1. Kích thước dữ liệu (Data Size): Cả 2 bộ đều có kích thước chuẩn ≈20,000 mẫu (King County có 21.6k, Indian Urban lấy mẫu 20k từ 80k), đảm bảo tính cân bằng tuyệt đối.
2. Chất lượng dữ liệu (Data Quality): Cả 2 bộ đều sạch 100% không bị rỗng nhãn hay khuyết thiếu, giúp nhóm sinh viên không bị mất điểm oan do lỗi xử lý dữ liệu bẩn.
3. Độ đa dạng đặc trưng (Feature Diversity): Tạo sự tương phản thú vị giữa bất động sản nhà vườn ngoại ô Mỹ (King County) và bất động sản căn hộ đô thị nén (Indian Urban).
4. Độ khó tiền xử lý (Difficulty): Cực kỳ vừa sức với sinh viên IT (chỉ mất ≈20 dòng code), chạy toàn bộ pipeline chỉ mất <20 giây.
5. Khả năng đạt kết quả mô hình (Expected Performance): Cả hai bộ dữ liệu đều cho kết quả thực nghiệm rất cao với mô hình XGBoost / Random Forest (
6. $R2 \approx 0.88-0.90$), giúp nhóm có được các bảng số liệu và biểu đồ đánh giá đẹp mắt, thuyết phục tối đa hội đồng chấm điểm.